Esercitazione:
Sviluppo di moduli per il kernel Linux

Corso di Laurea in Ingegneria Informatica

Università degli Studi di Napoli Federico II

Anno Accademico 2023/2024, Canale San Giovanni

Sommario

- Sommario
  - Cenni sull'architettura del kernel Linux
  - Configurazione, compilazione e installazione del kernel
  - Sviluppo di un modulo del kernel
  - Sviluppo di una chiamata di sistema
- Riferimenti
  - The Linux Kernel Module Programming Guide, http://tldp.org/LDP/lkmpg/2.6/html/ https://sysprog21.github.io/lkmpg/
  - R. Love, Linux Kernel Development (3ª ed.), cap. 2, 5, 17, 18

Struttura e compilazione del kernel Linux

Il kernel Linux

- Linux è un sistema operativo monolitico e modulare
  - Tutto il codice del kernel è contenuto in un unico file eseguibile
  - Utilizza un unico spazio di indirizzamento
  - Permette di caricare ulteriore codice da "moduli", a tempo di esecuzione

Architettura concettuale

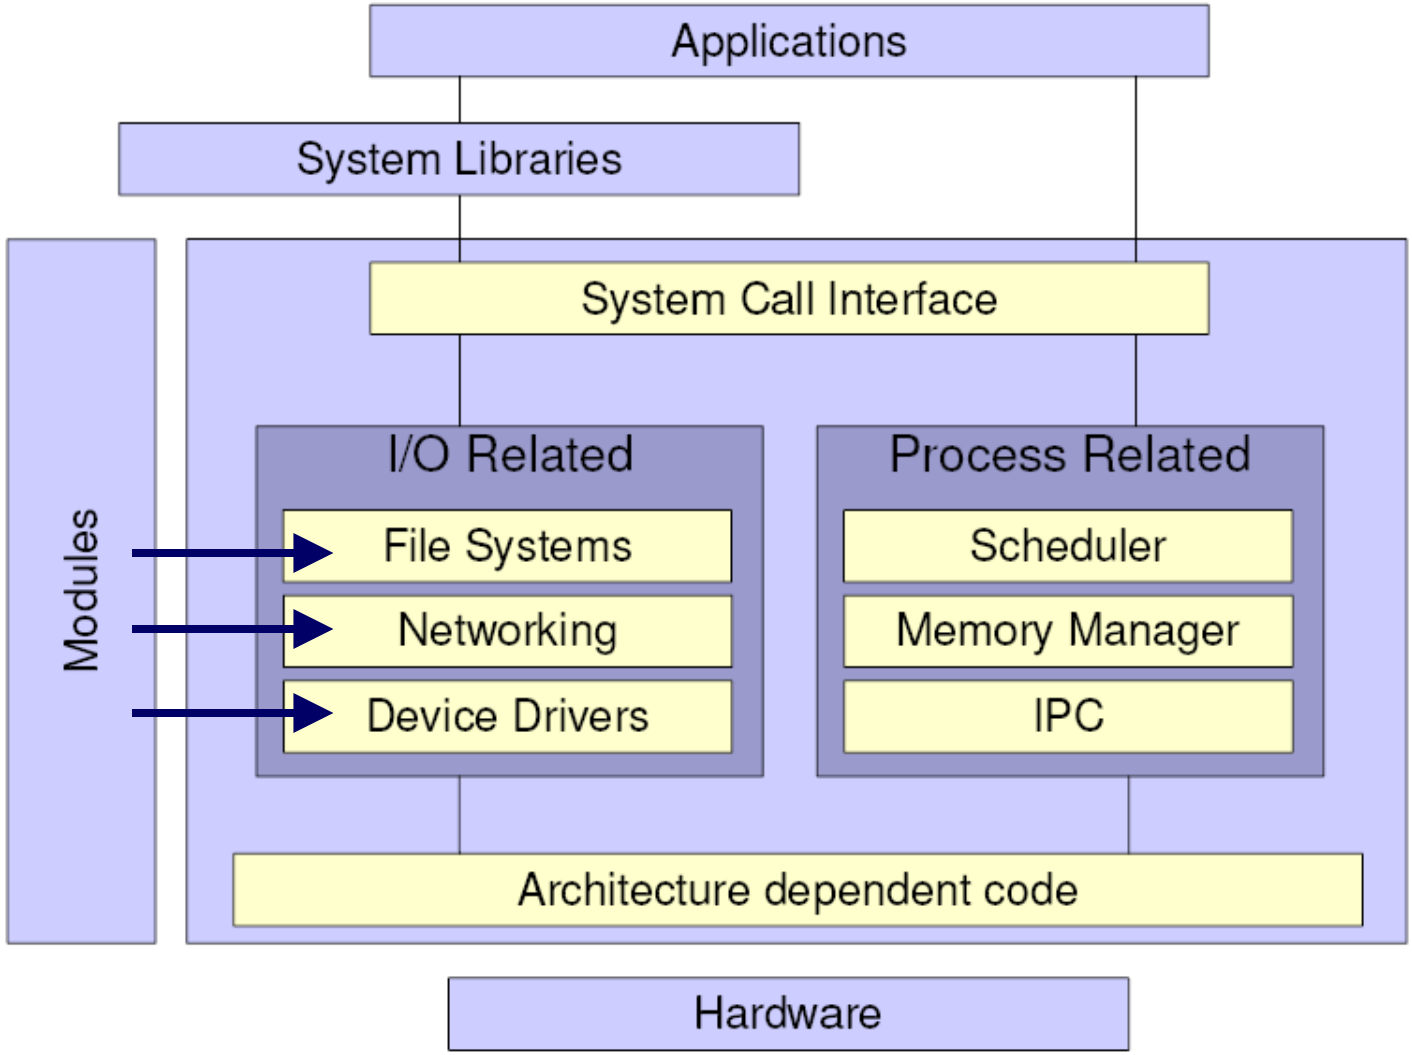

Moduli kernel

```
$ lsmod
Module                  Size  Used by
xt_conntrack           16384  1
nft_chain_nat          16384  3
xt_MASQUERADE          20480  1
...
e1000                 159744  0
scsi_transport_spi     36864  1 mptspi
mptscsih               45056  1 mptspi
mptbase               110592  2 mptspi,mptscsih
```

Device driver per schede di rete
Intel® Gigabit Ethernet Network Connection

Alcuni esempi di parti del kernel

- Versione "navigabile" del codice sorgente del kernel Linux: https://elixir.bootlin.com/

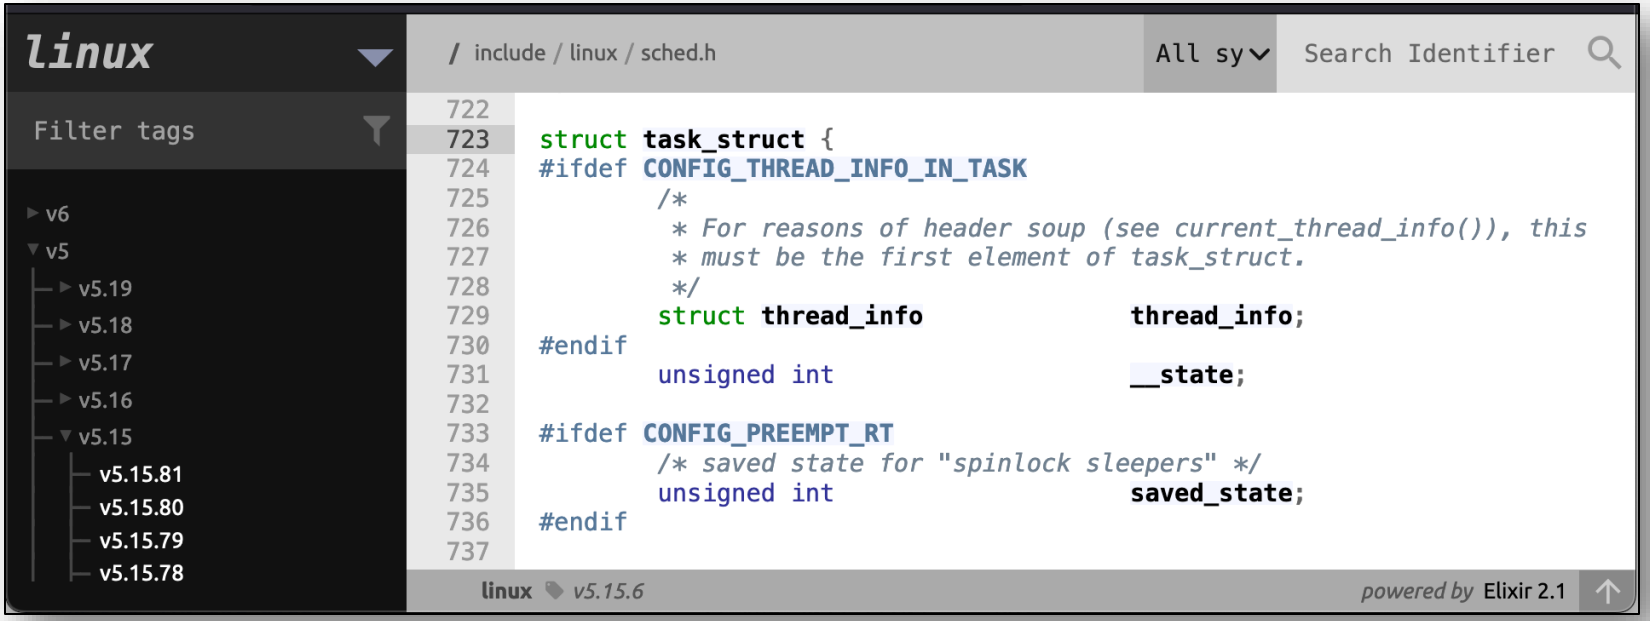

Alcuni esempi di parti del kernel

- Process control block (task_struct):
  - https://elixir.bootlin.com/linux/v5.15.6/source/include/linux/sched.h#L723
  - `int prio`
  - `struct mm_struct *mm`
  - `struct list_head tasks`
  - `struct task_struct *parent`
  - `char comm[TASK_COMM_LEN]`
- System call fork():
  - https://elixir.bootlin.com/linux/v5.9.11/source/kernel/fork.c#L2415
- ISR di un device driver per tastiera:
  - https://elixir.bootlin.com/linux/v5.9.11/source/drivers/input/keyboard/atkbd.c#L409

Compilazione del kernel

- Perché compilare il kernel?
  - Minore occupazione di memoria e storage (es. sistemi embedded)
  - Abilitare driver e funzionalità specifiche
  - Installare modifiche di terze parti
  - Ottimizzazione (es. selezione CPU family, SMP, layout memoria)
  - Utilizzo del sistema di build per sviluppare un nuovo modulo kernel
  - Studio del kernel!

KernelNewbies.org

- https://kernelnewbies.org

- Kernel hacking howtos
- Kernel changelog
- Kernel Janitors project
- Kernel mentors
- Job postings, career advice

Versione del kernel

```
$ uname -a
Linux Ubuntu-SO 5.15.0-53-generic #59-Ubuntu SMP Mon
Oct 17 18:53:30 UTC 2022 x86_64 x86_64 x86_64 GNU/Linux

$ uname -r
5.15.0-53-generic
```

È raccomandabile installare la **stessa versione (o simile) del kernel** già utilizzata dalla propria distribuzione

Dipendenze e sorgenti

- Prima di iniziare, occorre copiare i sorgenti, e installare librerie e tool necessari alla compilazione
  - Es. Ubuntu: https://wiki.ubuntu.com/Kernel/BuildYourOwnKernel

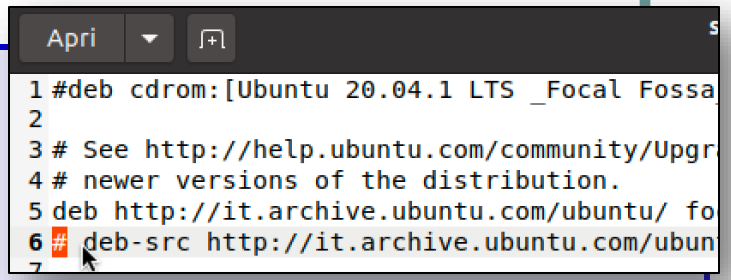


```
$ sudo gedit /etc/apt/sources.list
# togliere il cancelletto dalle righe con "deb-src"

$ sudo apt update

$ sudo apt build-dep linux linux-image-$(uname -r)

$ sudo apt install qt5-default

$ wget https://mirrors.edge.kernel.org/pub/linux/kernel/v5.x/linux-5.4.0.tar.gz

# Oppure:
# git clone git://git.kernel.org/pub/scm/linux/kernel/git/torvalds/linux.git
```

Cartella di lavoro

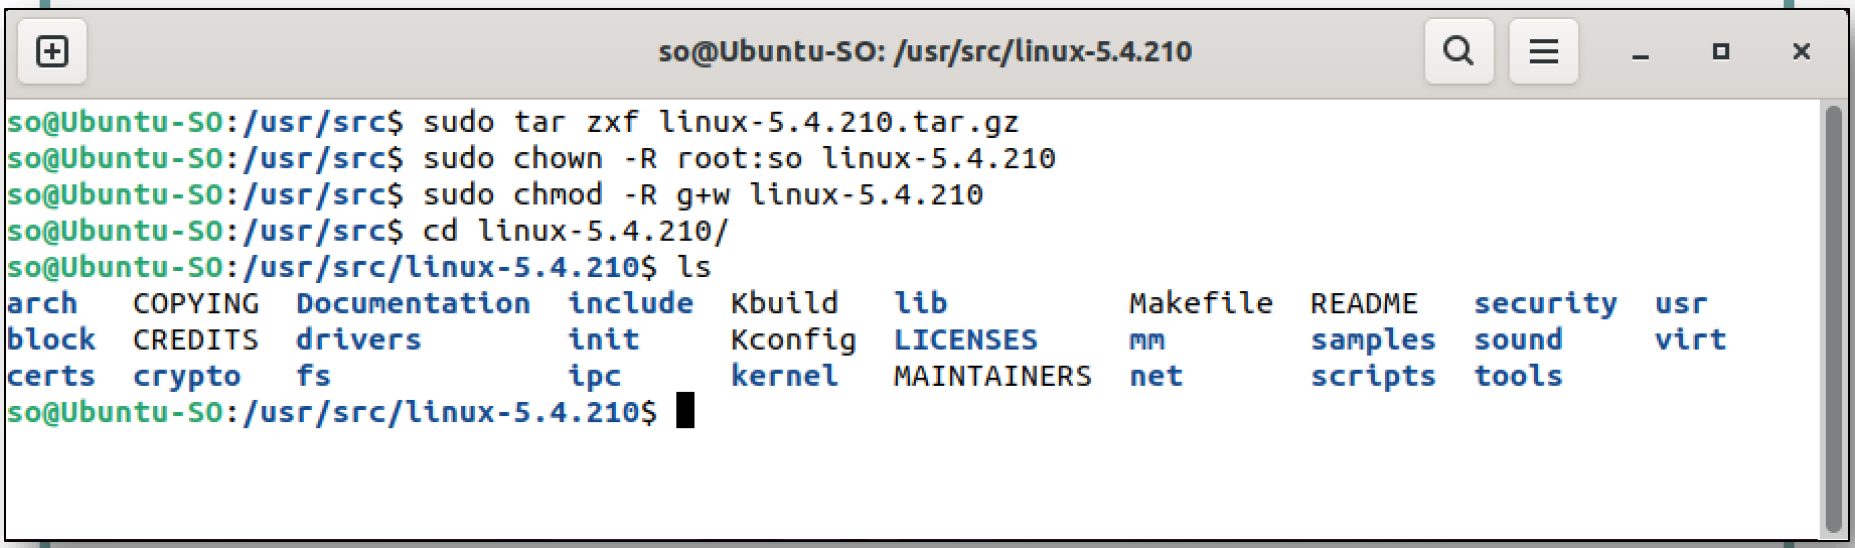

Configurazione del kernel

- La fase di configurazione permette di selezionare le funzionalità e i moduli da compilare, escludendo ciò che non serve

- Per modificare la configurazione, usare uno tra i seguenti comandi:

make xconfig	*(grafico, consigliato)*
make menuconfig	*(linea di comando)*
make config	*(linea di comando)*

Configurazione del kernel

- Per creare una configurazione di partenza:

  make localmodconfig

- Inizializza la configurazione in base ai **moduli in uso** nel sistema

Configurazione grafica

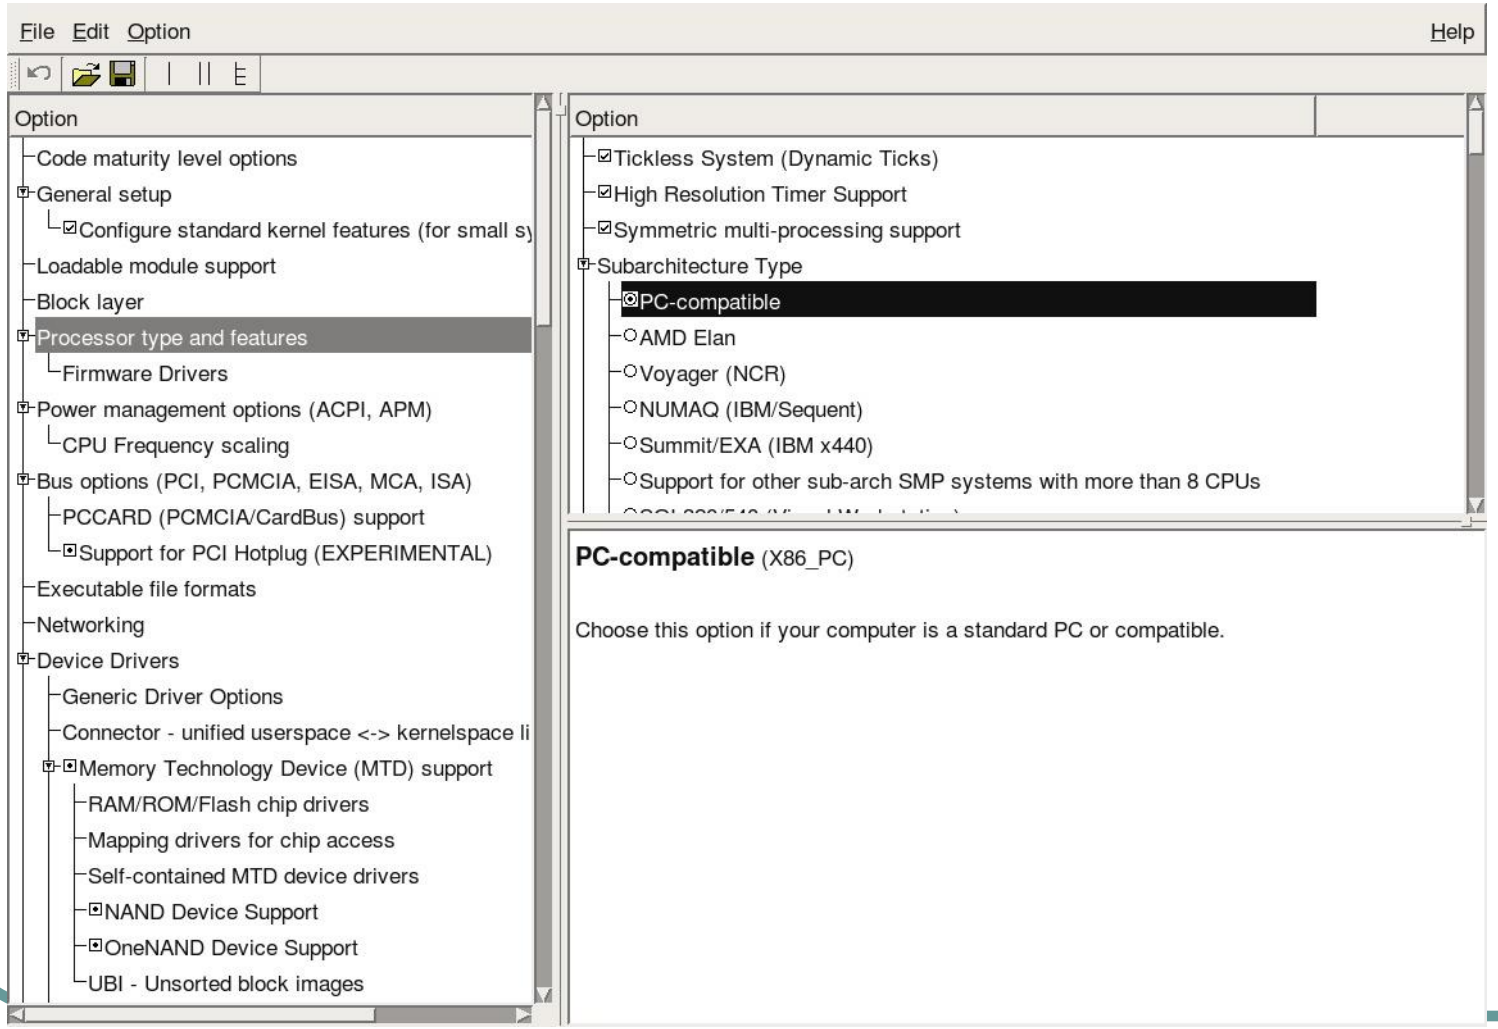

Opzioni di configurazione

- Ciascuna opzione può essere
  - compilata all'interno del kernel (Y, simbolo ✓)
  - compilata in un modulo separato (M, simbolo •)
  - esclusa dalla compilazione (N, casella vuota)
- Alcune opzioni richiedono valori numerici o stringhe

Opzioni di configurazione

- LOCALVERSION è il nome assegnato al kernel che compileremo
- LOCALVERSION="-CorsoSO": il nostro kernel sarà indicato con "5.4.0-CorsoSO"

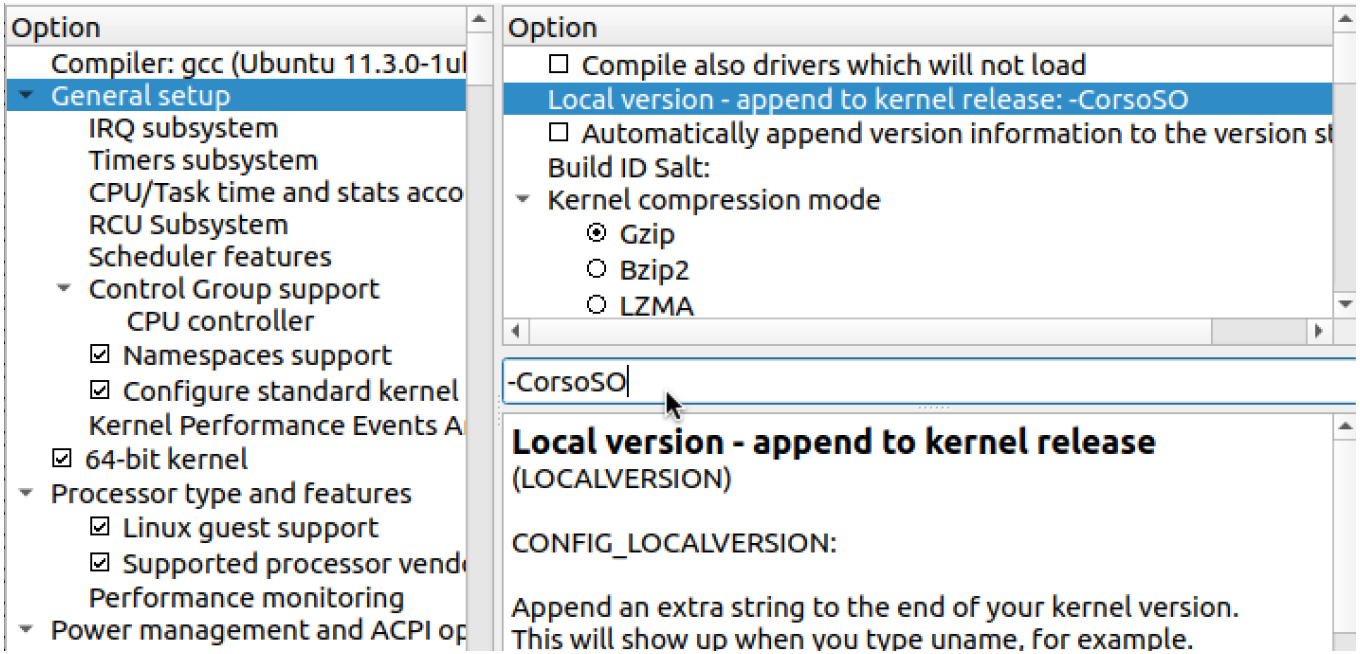

Alcuni esempi di opzioni

- Modalità di preemption del kernel
- Frequenza del timer
- Ottimizzazioni per la CPU (SMP, HyperThreading, famiglia di CPU,...)

Personalizzare la configurazione

- Molte opzioni riguardano il supporto hardware della macchina su cui il kernel sarà eseguito
- Per informazioni sul proprio hw:

```
lspci -vvv
cat /proc/cpuinfo
hal-device-manager
lsmod
```

Configurazione su una macchina virtuale VMware

$ lspci

.....

00:07.2 USB Controller: Intel Corporation 82371AB/EB/MB PIIX4 USB

00:07.3 Bridge: Intel Corporation 82371AB/EB/MB PIIX4 ACPI (rev 08)

00:0f.0 VGA compatible controller: VMware Inc [VMware SVGA II] PCI Display Adapter

00:10.0 SCSI storage controller: LSI Logic / Symbios Logic 53c1030 PCI-X Fusion-MPT Dual Ultra320 SCSI (rev 01)

00:11.0 PCI bridge: VMware Inc Unknown device 0790 (rev 02)

02:00.0 Ethernet controller: Advanced Micro Devices [AMD] 79c970 [PCnet32 LANCE] (rev 10)

02:01.0 Multimedia audio controller: Ensoniq ES1371 [AudioPCI-97] (rev 02)

02:02.0 USB Controller: VMware Inc Unknown device 0770

Esempio: opzioni per driver SATA

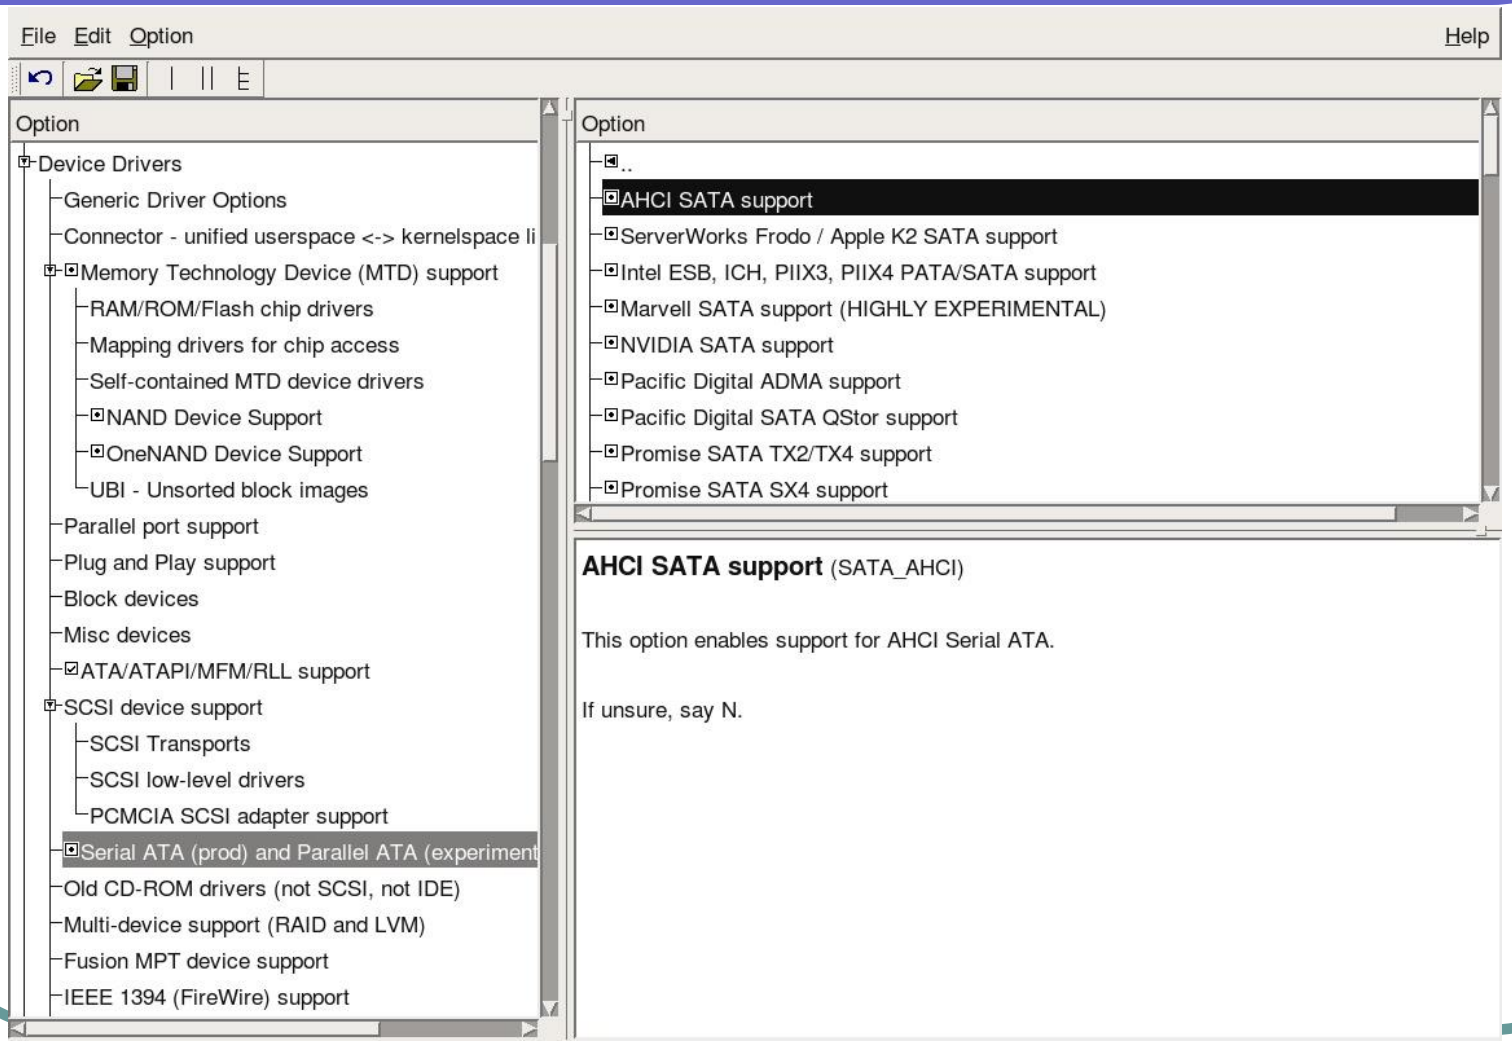

File di configurazione

- La configurazione viene salvata nel file **".config"** nella cartella dei sorgenti

```
so@Ubuntu-SO:/usr/src/linux-5.4.210$ ls -la
totale 1176
drwxrwxr-x  24 root so     4096 dic  3 17:41 .
drwxr-xr-x  12 root root   4096 dic  3 17:22 ..
drwxrwxr-x  27 root so     4096 ago 11 10:57 arch
drwxrwxr-x   3 root so     4096 dic  3 17:44 block
drwxrwxr-x   2 root so     4096 dic  3 17:33 certs
-rw-rw-r--   1 root so    15318 ago 11 10:57 .clang-format
-rw-rw-r--   1 root so       59 ago 11 10:57 .cocciconfig
-rw-rw-r--   1 so   so   139590 dic  3 17:32 .config
```

NOTA: I file che **iniziano con il punto (".")** sono detti **file invisibili**. Non sono mostrati dal comando "ls", ma occorre il comando "ls -a".

Compilazione

- Per rimuovere i file di una precedente compilazione:

  `make clean`

- Per compilare sia il kernel sia i moduli:

  `make`

- Per compilare in maniera parallela, utile per sfruttare SMP (es. 9 jobs se si hanno 8 core):

  `make -j 9`

Installazione

- Installare l'immagine del kernel nella cartella */boot*

```
sudo cp   arch/x86_64/boot/bzImage   /boot/vmlinuz-VERSIONE
```

- Copiare i moduli kernel nella cartella */lib/modules/*

```
sudo make modules_install
```

- Salvare una copia del file di configurazione:

```
sudo cp   .config   /boot/config-VERSIONE
```

Sostituire "VERSIONE" (es. con "5.4.0-CorsoSO")

Cartella /boot

so@Ubuntu-SO: /usr/src

```
so@Ubuntu-SO:/usr/src$ ls -l /boot/
totale 195632
-rw-r--r-- 1 root root   261841 ago 10 07:49 config-5.15.0-47-generic
-rw-r--r-- 1 root root   261861 ott 13 07:40 config-5.15.0-52-generic
-rw-r--r-- 1 root root   261837 ott 17 18:36 config-5.15.0-53-generic
-rw-r--r-- 1 root root   139590 dic  3 18:02 config-5.4.210-CorsoSO
drwxr-xr-x 5 root root     4096 dic  5 16:14 grub
lrwxrwxrwx 1 root root       28 nov 22 12:33 initrd.img -> initrd.img-5.15.0-53-generic
-rw-r--r-- 1 root root 32745364 set 15 12:37 initrd.img-5.15.0-47-generic
-rw-r--r-- 1 root root 32750951 ott 26 12:46 initrd.img-5.15.0-52-generic
-rw-r--r-- 1 root root 32746358 nov 22 12:38 initrd.img-5.15.0-53-generic
-rw-r--r-- 1 root root 35900964 dic  5 16:14 initrd.img-5.4.210-CorsoSO
lrwxrwxrwx 1 root root       28 nov 22 12:33 initrd.img.old -> initrd.img-5.15.0-52-generic
-rw------- 1 root root  6245466 ago 10 07:49 System.map-5.15.0-47-generic
-rw------- 1 root root  6249017 ott 13 07:40 System.map-5.15.0-52-generic
-rw------- 1 root root  6250186 ott 17 18:36 System.map-5.15.0-53-generic
lrwxrwxrwx 1 root root       25 nov 22 12:33 vmlinuz -> vmlinuz-5.15.0-53-generic
-rw------- 1 root root 11530816 ago 11 07:44 vmlinuz-5.15.0-47-generic
-rw------- 1 root root 11543392 ott 13 07:49 vmlinuz-5.15.0-52-generic
-rw------- 1 root root 11548224 ott 17 18:41 vmlinuz-5.15.0-53-generic
-rw-r--r-- 1 root root 11864384 dic  5 16:13 vmlinuz-5.4.210-CorsoSO
lrwxrwxrwx 1 root root       25 nov 22 12:33 vmlinuz.old -> vmlinuz-5.15.0-52-generic
so@Ubuntu-SO:/usr/src$
```

La cartella /boot raccoglie i file del kernel

- config
- initrd.img
- vmlinuz
- System.map (opzionale)

Cartella /lib/modules

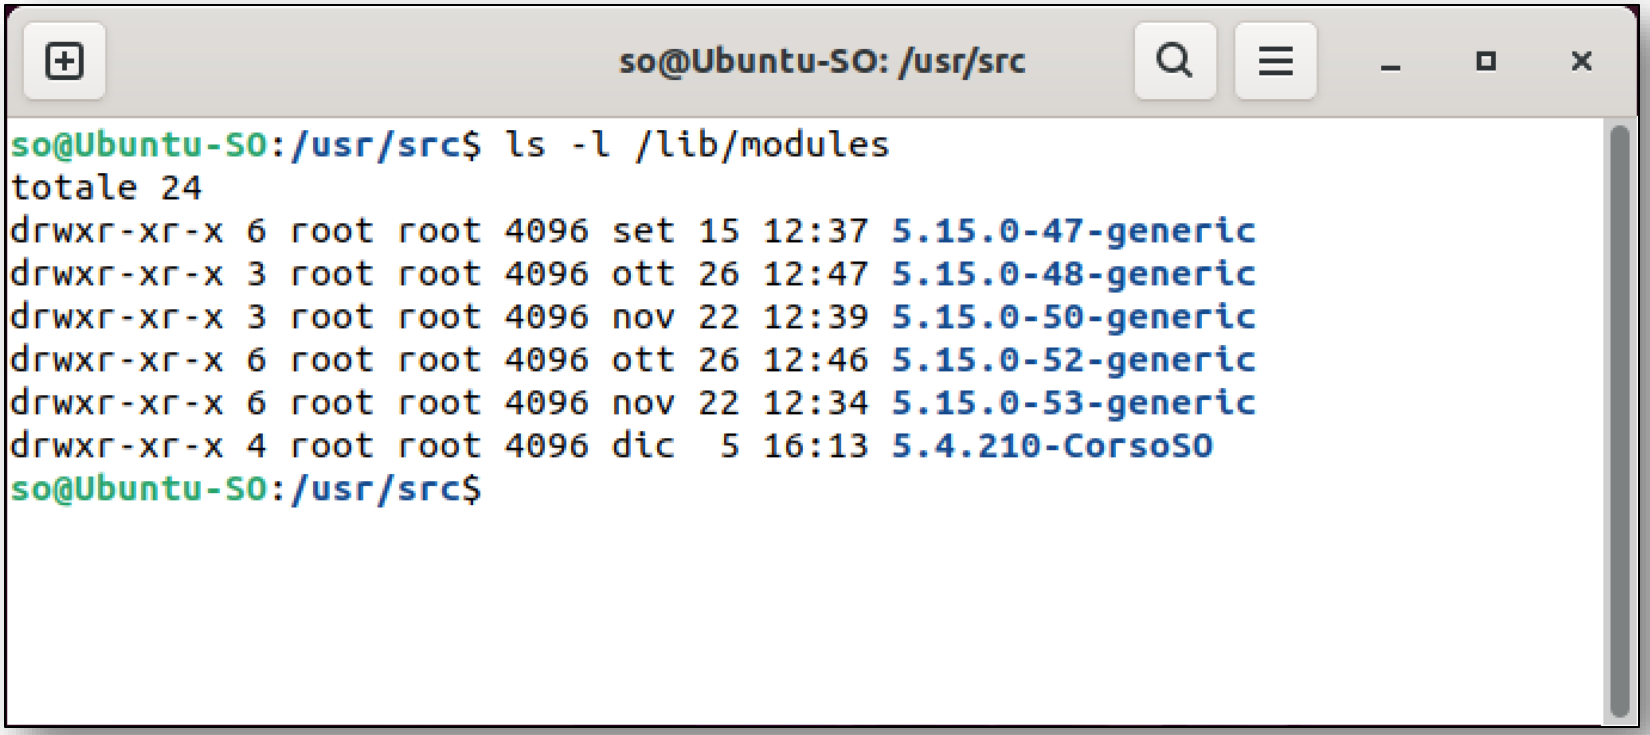

La cartella /lib/modules raccoglie i moduli del kernel (una sottocartella per ogni versione)

Bootstrap del nuovo kernel

- Il **bootloader** è un piccolo programma che viene eseguito all'avvio del computer
- Viene prelevato dal **BIOS** dai primi settori del disco
- Il bootloader può interagire con l'utente per selezionare quale sistema operativo avviare

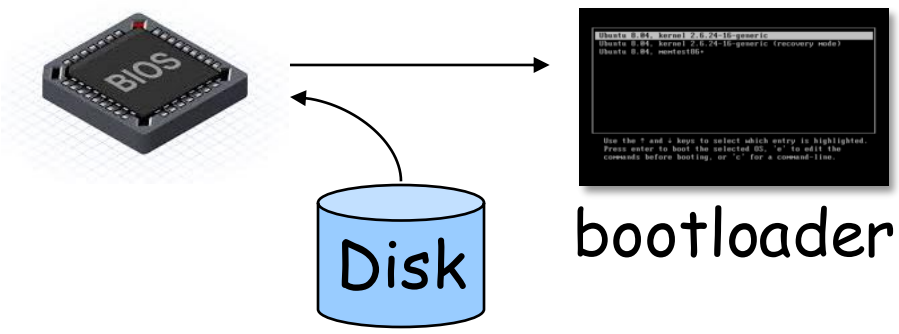

Caricamento Driver di I/O

- Il kernel ha bisogno dei **driver di I/O** (es., disco, rete, filesystem) per **caricare i moduli** al **boot**
- ...e se a loro volta anche i **driver di I/O sono moduli**?

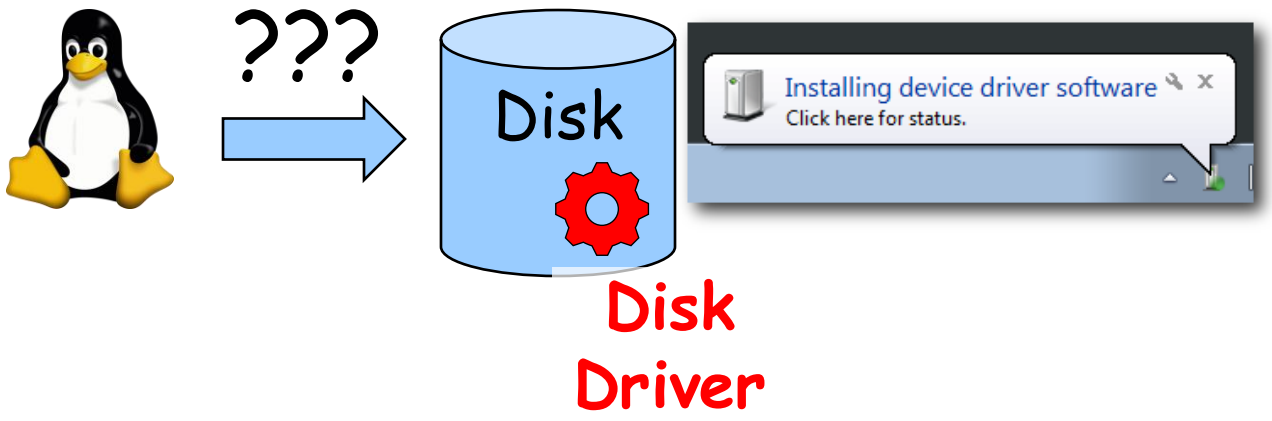

Caricamento Driver di I/O

- È il caso tipico delle distribuzioni Linux
  - Le distribuzioni includono il maggior numero possibile di driver di I/O, per maggiore compatibilità
  - I driver sono compilati come moduli
  - Evita che il file vmlinuz diventi eccessivamente grande

```
$ find /lib/modules/$(uname -r) -name "*.ko" | wc -l
1022
```

Initial RAM Disk (initrd)

- I moduli strettamente necessari sono copiati in un file detto "**initial RAM disk**"
- Il **bootloader** carica questo file su RAM
- Il kernel preleva da lì il driver del disco

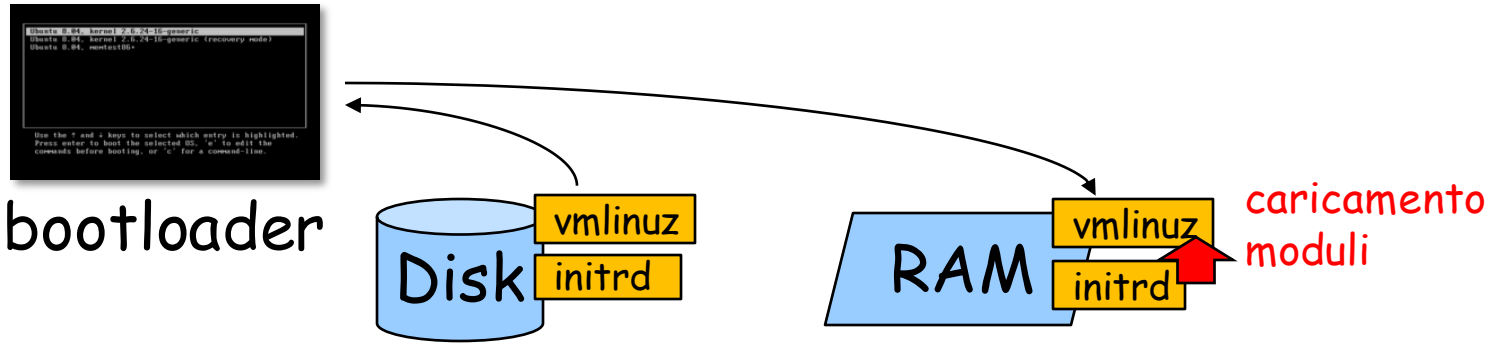

Creazione Initial RAM Disk

- Il comando va eseguito **dopo aver installato i moduli** con *make modules_install*
- Per creare l'initial RAM disk:

```
sudo mkinitramfs -o /boot/initrd.img-VERSIONE  VERSIONE
```

- Ad esempio:

```
sudo mkinitramfs
            -o /boot/initrd.img-5.4.0-CorsoSO   5.4.0-CorsoSO
```

- Altre distribuzioni utilizzano il programma *mkinitrd*

Configurazione bootloader

- Occorre **configurare il bootloader** per utilizzare il kernel appena compilato
- **GRUB** è il bootloader più comune tra le distribuzioni Linux

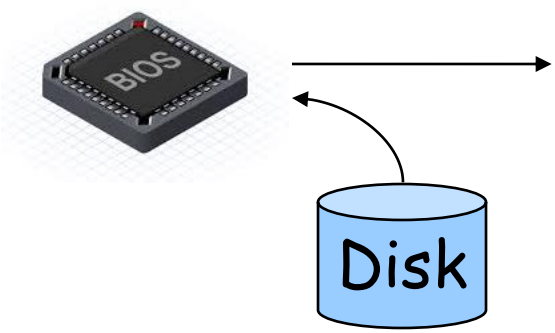

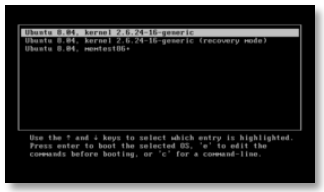

bootloader

GRUB

- Modificare il file */etc/default/grub*, per fare apparire il menù di GRUB all'avvio
  - Aggiungere **#** all'inizio della riga *GRUB_TIMEOUT_STYLE=hidden*
  - Impostare *GRUB_TIMEOUT* a un valore maggiore di 0
- Aggiornare GRUB:

```
sudo update-grub
```

- Al prossimo riavvio, si potrà scegliere di avviare il nuovo kernel invece di quello di default

NOTA: il comando "make install" copia automaticamente i file vmlinuz e initrd in /boot, ed aggiorna il bootloader

GRUB

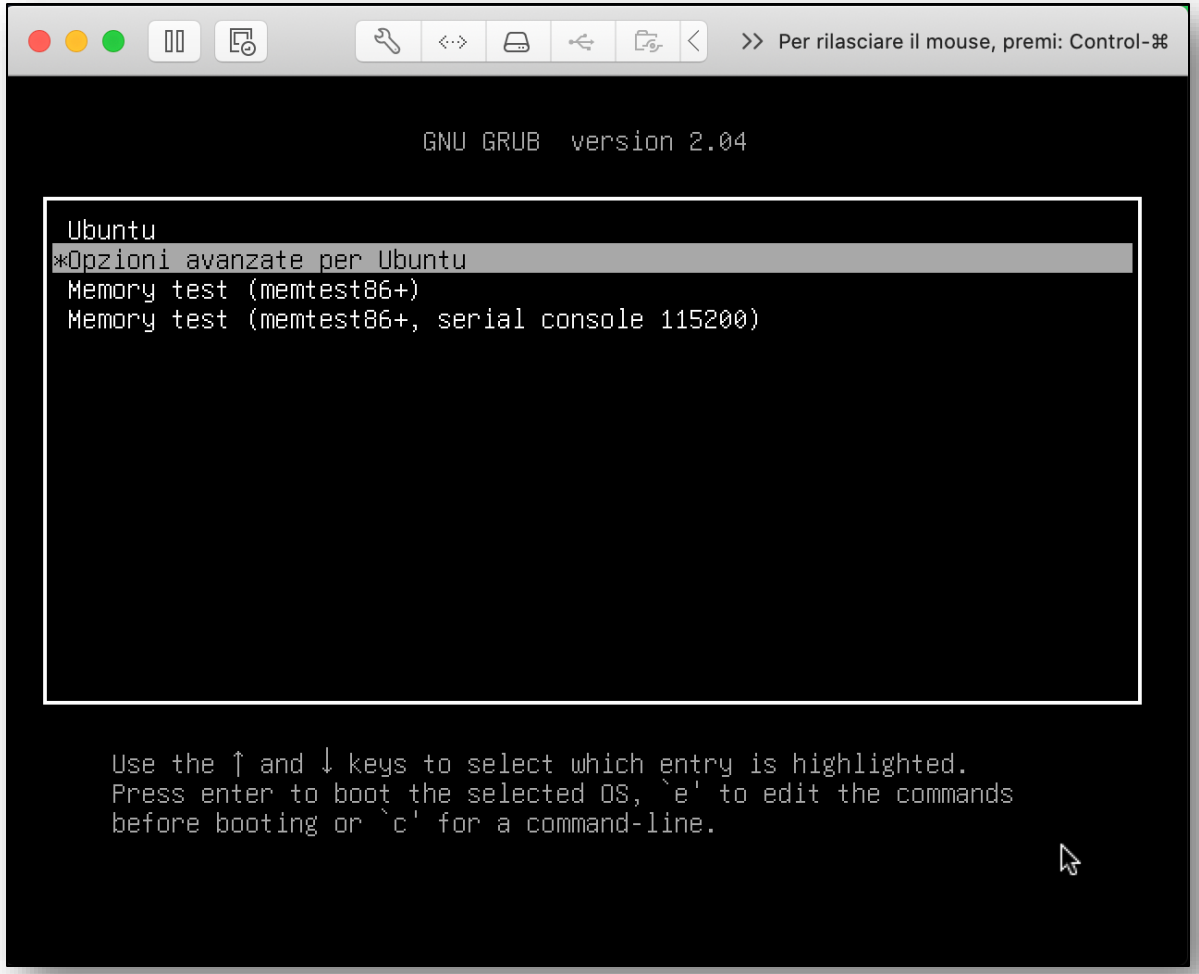
Per rilasciare il mouse, premi: Control-⌘
GNU GRUB version 2.04
Ubuntu
*Opzioni avanzate per Ubuntu
Memory test (memtest86+)
Memory test (memtest86+, serial console 115200)
Use the ↑ and ↓ keys to select which entry is highlighted.
Press enter to boot the selected OS, `e' to edit the commands
before booting or `c' for a command-line.

...ricapitolando (procedura semplificata)

1. Scaricare i sorgenti (es., dal sito www.kernel.org)
2. Effettuare la configurazione
   - **sudo make localmodconfig** (seleziona automaticamente i moduli kernel in uso nel sistema)
   - Modificare la configurazione, settando il parametro LOCALVERSION (es., la stringa "-CorsoSO")
3. Lanciare la compilazione
   - **sudo make**
4. Installare i moduli
   - **sudo make modules_install**
5. Installare vmlinuz e aggiornare il bootloader
   - **sudo make install**

Utilizzo del nuovo kernel

- Comando per verificare la versione del kernel in uso:

```
uname -a
```

- Se si usa un nuovo kernel in una VM, può occorrere installare nuovamente i **vmware-tools**
  - Essi includono dei moduli kernel, che vanno ricompilati per poter essere eseguiti nel nuovo kernel

Errori comuni

- La **configurazione** del kernel non include alcuni moduli necessari all'avvio
  - es., i driver del disco oppure il filesystem
- La **creazione dello Initial RAM Disk** è fallita
  - non bisogna ignorare eventuali warning durante la creazione
- Errori nelle **convenzioni dei nomi**
  - es., l'uso della stringa LOCALVERSION all'interno dei nomi dei file

Note (VM del corso)

- Prima di creare lo Init RAM Disk, cancellare il file:
  `/etc/default/grub.d/50-cloudimg-settings.cfg`

- Prima di lanciare update-grub, modificare il file:
  `/etc/initramfs-tools/initramfs.conf`
  configurando COMPRESS=bzip2

Linux Kernel Modules (LKM)

Moduli del kernel Linux

- I moduli del kernel permettono di rendere il sistema più flessibile:
  - Installazione di software di terze parti (es., device driver)
  - Caricamento di funzionalità on-demand
  - Sviluppo e collaudo di nuovo codice senza dover riavviare il sistema

Ciclo di vita di un modulo

- I sorgenti del modulo vengono compilati sfruttando i **tool** (**Kbuild**) e gli **header file** inclusi nei **sorgenti del kernel**
- Il modulo viene caricato **dinamicamente**, su richiesta dell'utente, oppure dai processi di sistema

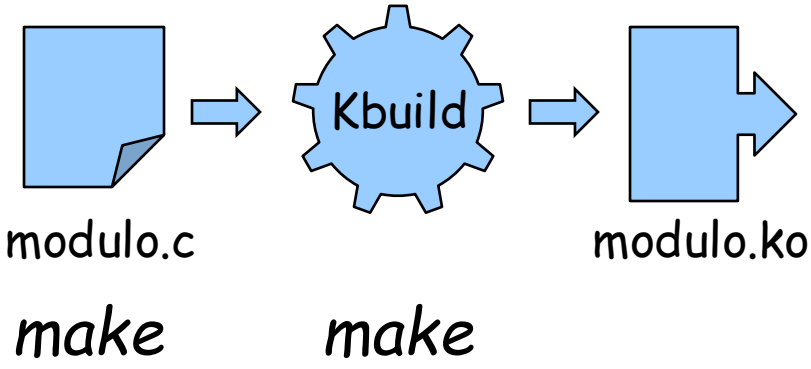

insmod modulo.ko

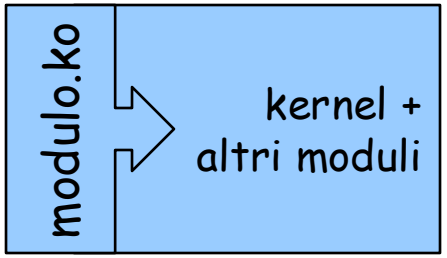

Esecuzione del modulo

- Un modulo è una collezione di funzioni ("entry point")
- Eseguite quando si verificano:
  - **Caricamento** e **rimozione** del modulo
  - **Chiamate di sistema**
    (o altre interazioni tra user- e kernel-mode)
  - **Interruzioni**

Un semplice modulo

```
#include <linux/module.h> /* Needed by all modules */
#include <linux/kernel.h> /* Needed for KERN_INFO */

MODULE_LICENSE("GPL");

int init_module(void) {
        printk(KERN_INFO "Hello world 1.\n");

        return 0;
}
void cleanup_module(void) {
        printk(KERN_INFO "Goodbye world 1.\n");
}
```

La funzione printk

- Il codice del kernel **non ha associato un terminale** su cui far apparire messaggi!
- **printk()** scrive su un buffer circolare, e i messaggi sono rediretti verso un processo di sistema (**syslogd**)
- Consultabili via:
  - il comando **dmesg**
  - il file di log (**/var/log/syslog**)
  - in tutti i terminali (nei casi da alta severità)

Logging nel kernel

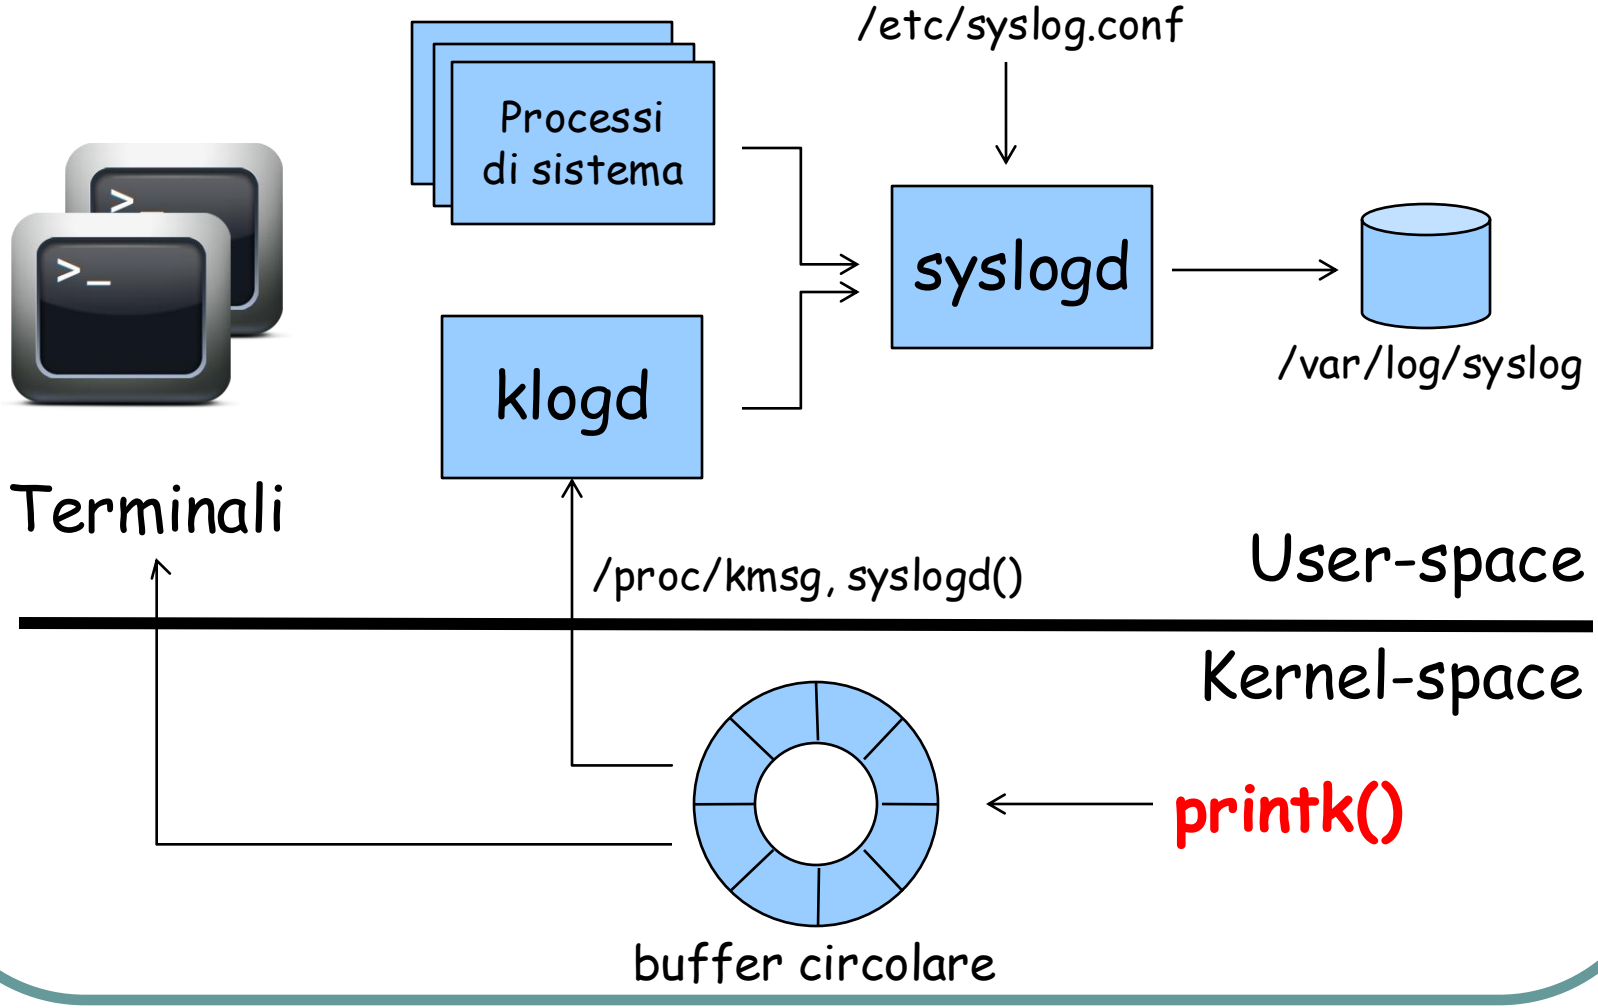

Livelli di severità dei log

Loglevel	Description
KERN_EMERG	An emergency condition; the system is probably dead.
KERN_ALERT	A problem that requires immediate attention.
KERN_CRIT	A critical condition.
KERN_ERR	An error.
KERN_WARNING	A warning.
KERN_NOTICE	A normal, but perhaps noteworthy, condition.
KERN_INFO	An informational message.
KERN_DEBUG	A debug message—typically superfluous.

Makefile di un modulo

- La compilazione si basa sul sistema **Kbuild** di compilazione del kernel (Makefile e script per la shell)
- I sorgenti ed il Makefile del nuovo modulo possono risiedere in qualunque directory

```
obj-m += hello-1.o

VERSIONE_KERNEL=$(shell uname -r)

all:
        make -C /lib/modules/$(VERSIONE_KERNEL)/build M=$(PWD) modules
clean:
        make -C /lib/modules/$(VERSIONE_KERNEL)/build M=$(PWD) clean
```

Directory corrente

È un link simbolico verso la cartella dei sorgenti del kernel (creato da "make modules_install")

Compilazione ed utilizzo

- Compilazione:

```
$ make
make -C /lib/modules/5.4.0-56-generic/build M=/home/so/so_esempi/moduli-kernel/hello-1 modules
make[1]: ingresso nella directory «/usr/src/linux-headers-5.4.0-56-generic»
  CC [M]  /home/so/so_esempi/moduli-kernel/hello-1/hello-1.o
  Building modules, stage 2.
  MODPOST 1 modules
WARNING: modpost: missing MODULE_LICENSE() in /home/so/so_esempi/moduli-kernel/hello-1/hello-1.o
see include/linux/module.h for more information
  CC [M]  /home/so/so_esempi/moduli-kernel/hello-1/hello-1.mod.o
  LD [M]  /home/so/so_esempi/moduli-kernel/hello-1/hello-1.ko
make[1]: uscita dalla directory «/usr/src/linux-headers-5.4.0-56-generic»
```

- Caricamento: `sudo insmod ./hello-1.ko`
- Visualizzazione elenco moduli: `lsmod`
- Rimozione: `sudo rmmod hello-1`
- Informazioni sul modulo: `modinfo ./hello-1.ko`

Avvertenze per la programmazione kernel-space

- A differenza dei processi, un bug nella gestione della memoria nel kernel (es. indirizzo invalido) **rende instabile l'intero sistema**
- Un "**oops**" è un messaggio diagnostico prodotto a seguito di eccezioni occorse in kernel-mode
  - Il kernel prova ad uccidere il processo corrente e a continuare l'esecuzione

Kernel panic

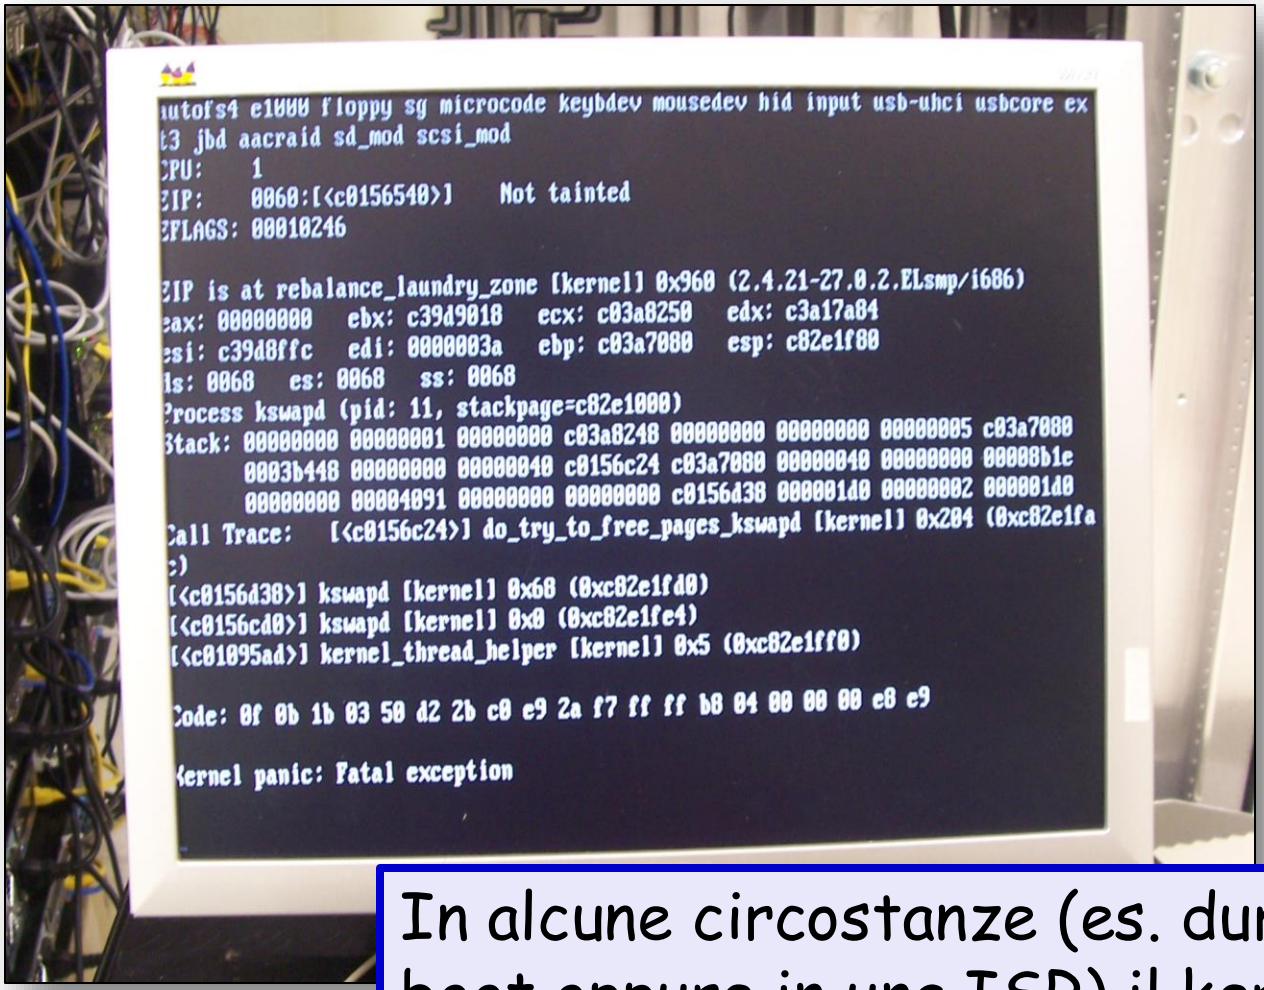

In alcune circostanze (es. durante il boot oppure in una ISR) il kernel si ferma (stato di **kernel panic**)

Kernel panic

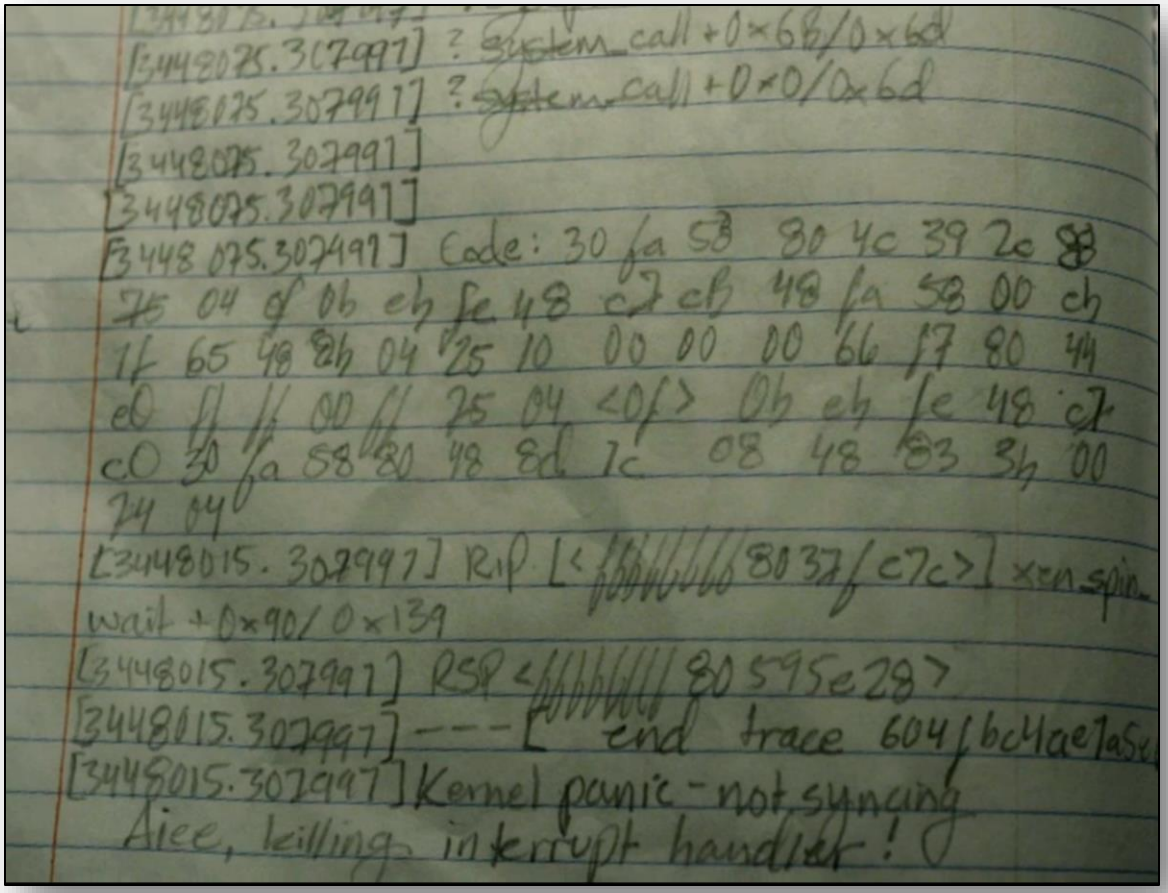

Avvertenze per la programmazione kernel-space

- Il kernel **non può utilizzare le funzioni di libreria C**
- Si utilizzano invece dei sostituti:
  - **Logging**: printk()
  - **Allocazione memoria**: kmem_cache_alloc(), kmalloc()
  - **Sincronizzazione**: spin_lock()/unlock(), wake_up_interruptible()
  - ...

Avvertenze per la programmazione kernel-space

- L'aritmetica floating point non è di semplice utilizzo (per via della gestione delle eccezioni)
- Gli stack del kernel sono limitati (1 o 2 pagine)
- Occorre gestire la **sincronizzazione** con altre parti del kernel (system call, ISR, kernel threads, ...) che accedono a dati comuni (ad esempio il PCB)

Un device driver fittizio

- Esempio: device driver per **dispositivo a caratteri** (fittizio)

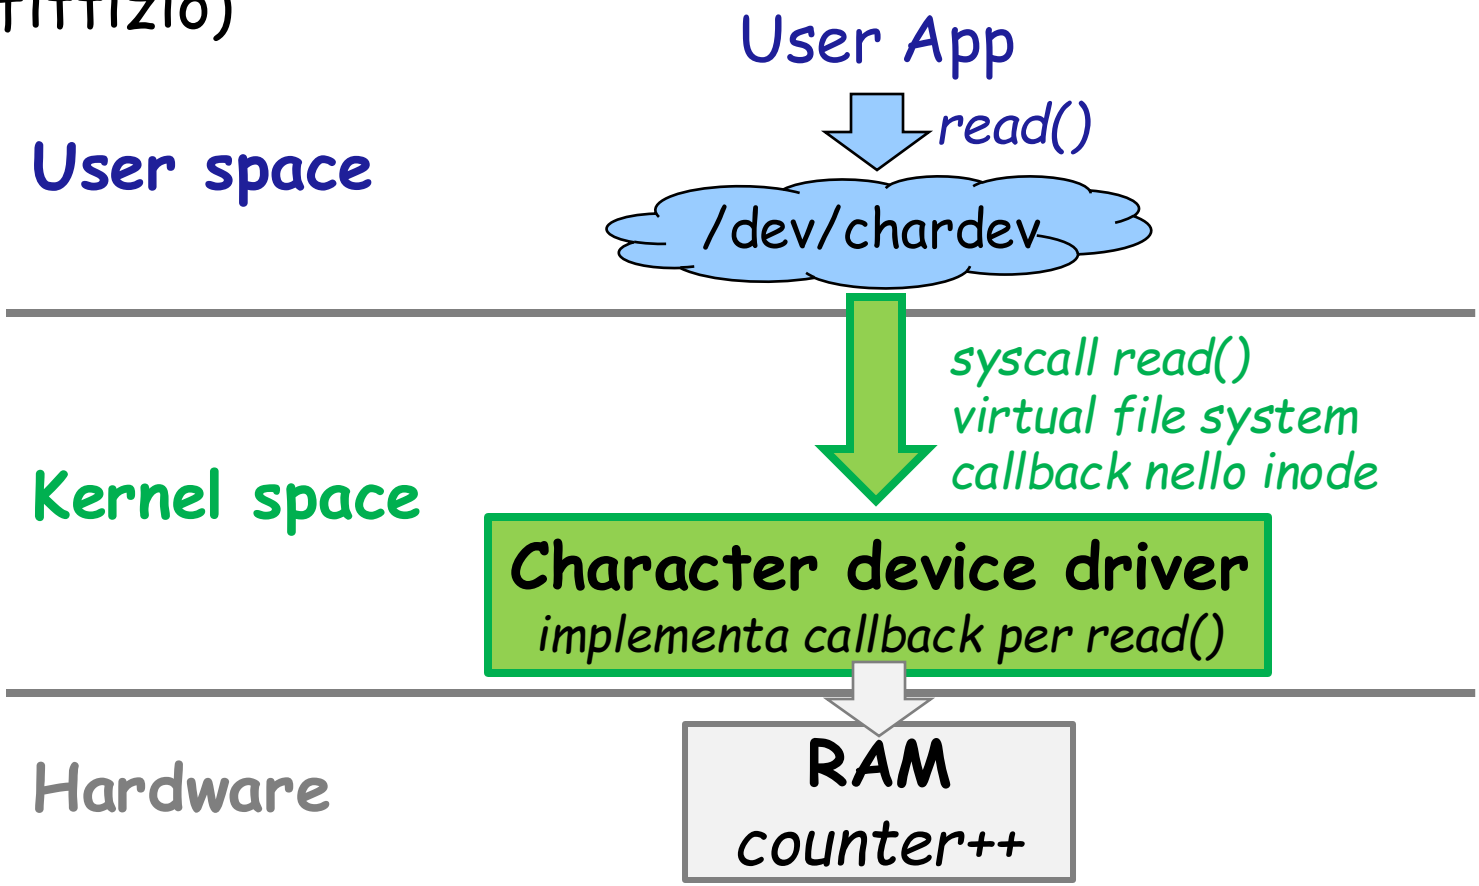

Un device driver fittizio

- Un processo può leggere/scrivere il file virtuale **/dev/chardev**
- Il SO richiama le funzioni del device driver
  - Lettura (system call open + read):
    il device driver **copia una stringa** con il numero di volte che il file è stato acceduto
  - Scrittura (system call write):
    ignorate, scrive un log e ritorna un errore al processo chiamante

Esempio chardev

```
# insmod chardev.ko
# dmesg
...
I was assigned major number 249

# mknod /dev/chardev c 249 0

# cat /dev/chardev
I already told you 0 times Hello world!
# cat /dev/chardev
I already told you 1 times Hello world!
...
```

Esempio chardev

```
# insmod chardev.ko
# dmesg
...
I was assigned major number 249

# mknod /dev/chardev c 249 0

# cat /dev/chardev
I already told you
# cat /dev/chardev
I already told you 1 times Hello world!
...
```

Il comando **mknod** crea un **device file**, e lo abbina al modulo appena caricato in base ad un "**major number**"

Major e minor number

- Il **major number** è un numero identificativo del driver che deve gestire un device file
  - Il major number può essere scelto dallo sviluppatore, oppure **scelto dinamicamente** dal kernel
- Il **minor number** è un numero secondario, nel caso un driver gestisca più device file

Major e minor number

- Il **major number** essenzialmente identifica una classe di dispositivi
  - es. i driver SCSI avranno lo stesso major number
  - sono documentati nei sorgenti del kernel Linux (*Documentation/admin-guide/devices.txt*)

```
$ ls -l /dev

...
brw-rw----  1 root disk      8,   0 dic 10 01:47 sda
brw-rw----  1 root disk      8,   1 dic 10 01:47 sda1

...
crw--w----  1 root tty       4,   0 dic 10 01:47 tty0
```

Registrazione del driver

- Il modulo del device driver deve
  - **registrarsi** come tale presso il kernel
  - registrare le **funzioni del modulo** atte a gestire le operazioni sul device file (apertura, lettura, scrittura, ...)

```
int register_chrdev( unsigned int major,
                     const char *name,
                     struct file_operations *fops );
```

- Esistono funzioni analoghe per altre **classi di dispositivi** (es., USB, SATA, Ethernet, ...)

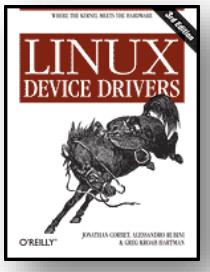

Linux Device Drivers, 3rd Ed.
https://lwn.net/Kernel/LDD3/

Operazioni su device a caratteri

```
struct file_operations {
  struct module *owner;
  ...
  int (*open) (struct inode *, struct file *);

  ssize_t(*read) ( struct file *, char __user *,
                   size_t, loff_t * );

  ssize_t(*write) ( struct file *, const char __user *,
                    size_t, loff_t * );
  ...
};
```

Struttura del modulo

```
int init_module(void);
void cleanup_module(void);
static int device_open(struct inode *, struct file *);
static int device_release(struct inode *, struct file *);
static ssize_t device_read(struct file *, char *, size_t, loff_t *);
static ssize_t device_write(struct file *, const char *, size_t, loff_t *);

static int Major;          /* Major number assigned to our device driver */
static int Device_Open = 0;  /* Is device open?
                              * Used to prevent multiple access to device */
static char msg[BUF_LEN]; /* The msg the device will give when asked */
static char *msg_Ptr;

static struct file_operations fops = {
        .read = device_read,
        .write = device_write,
        .open = device_open,
        .release = device_release
};
```

Inizializzazione del modulo

```
int init_module(void)
{
        Major = register_chrdev(0, DEVICE_NAME, &fops);

        if (Major < 0) {
          printk(KERN_ALERT "Registering char device failed with %d\n", Major);
          return Major;
        }

        printk(KERN_INFO "I was assigned major number %d. To talk to\n", Major);
        printk(KERN_INFO "the driver, create a dev file with\n");
        printk(KERN_INFO "'mknod /dev/%s c %d 0'.\n", DEVICE_NAME, Major);
        printk(KERN_INFO "Try various minor numbers. Try to cat and echo to\n");
        printk(KERN_INFO "the device file.\n");
        printk(KERN_INFO "Remove the device file and module when done.\n");

        return SUCCESS;
}
```

Operazione di apertura

```
/*
 * Called when a process tries to open the device file, like
 * "cat /dev/mycharfile"
 */
static int device_open(struct inode *inode, struct file *file)
{
        static int counter = 0;

        if (Device_Open)
                return -EBUSY;

        Device_Open++;
        sprintf(msg, "I already told you %d times Hello world!\n", counter++);
        msg_Ptr = msg;

        try_module_get(THIS_MODULE);

        return SUCCESS;
}
```

Operazione di lettura

```
static ssize_t device_read(
                struct file *filp,          /* see include/linux/fs.h   */
                char *buffer,               /* buffer to fill with data */
                size_t length,              /* length of the buffer     */
                loff_t * offset ) {

    int bytes_read = 0;  // Number of bytes actually written to the buffer

    if (*msg_Ptr == 0)    // If we're at the end of the message,
        return 0;         // return 0 signifying end of file

    while (length && *msg_Ptr) {
        /* The buffer is in the user data segment, not the kernel segment, so
         * "*" assignment won't work.  We have to use put_user which copies
         * data from the kernel data segment to the user data segment.*/
        put_user(*(msg_Ptr++), buffer++);
        length--;
        bytes_read++;
    }
    return bytes_read;
}
```

Chiamate di sistema

Chiamate di sistema

- Le chiamate di sistema sono l'interfaccia tra i processi e il SO
- Passaggio della CPU dalla modalità utente (esecuzione dei processi) alla modalità kernel (esecuzione del codice del kernel)
- Linux fornisce oltre 300 chiamate di sistema (in parte basate sullo standard IEEE POSIX)

La libreria C

- Le chiamate di sistema sono incapsulate ("wrapped") dalla libreria C

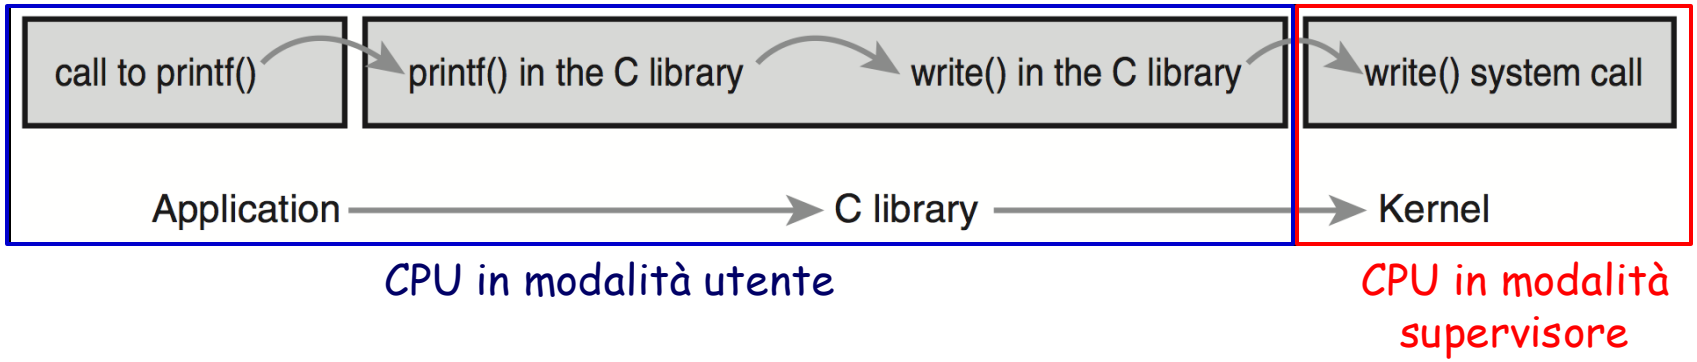

Esempio di chiamata di sistema

- Le funzioni nel kernel che implementano syscall hanno il prefisso "**sys_**"

```
asmlinkage long sys_getpid(void) {
        return current->tgid;
}
```

- "current" è un puntatore globale al PCB del processo in esecuzione
- In Linux, il PID di un processo è anche detto "**Thread Group ID**" (TGID)

Invocazione di una chiamata di sistema

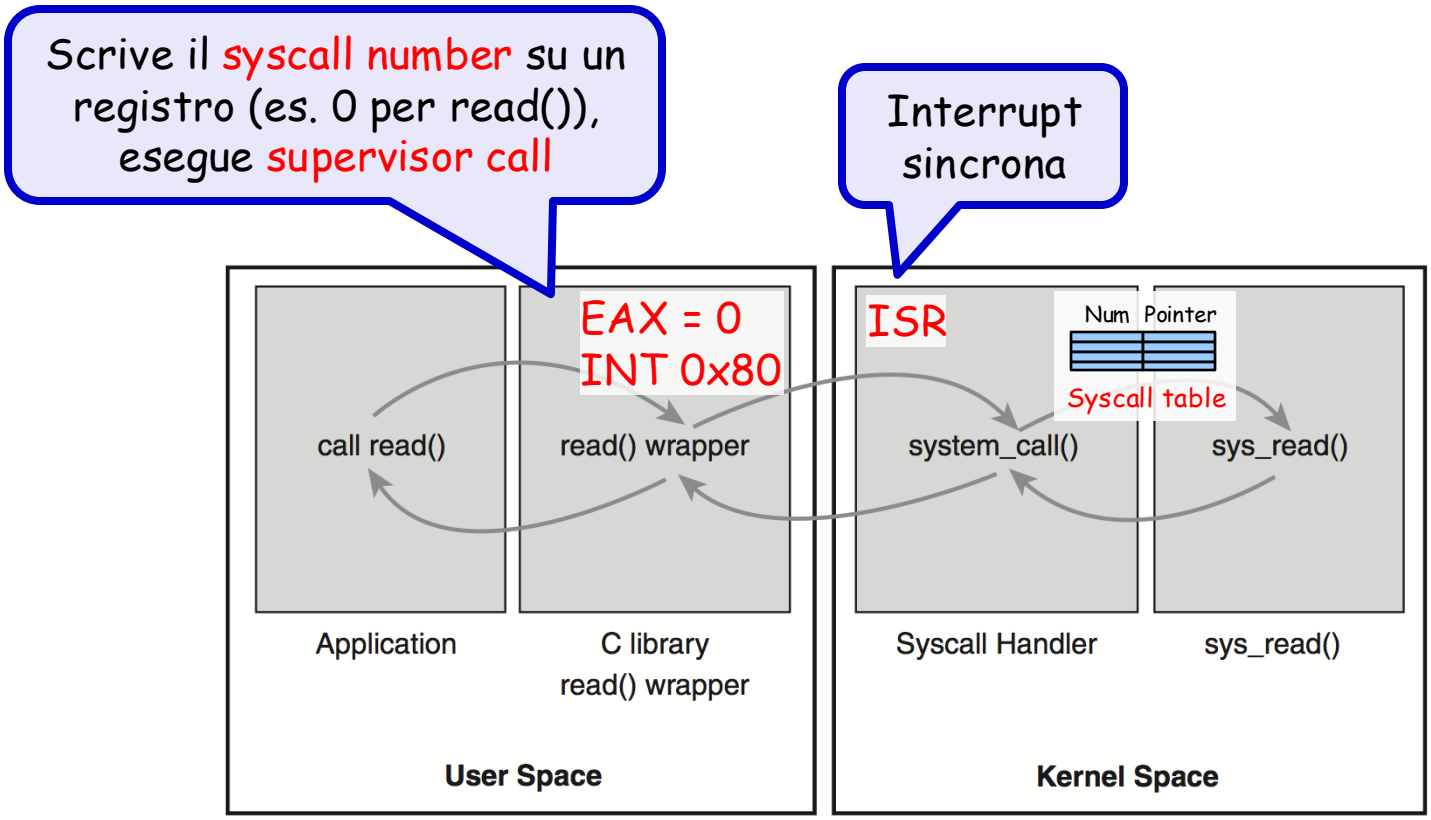

La ISR (syscall handler) cerca il syscall number nella **syscall table**, e trova il puntatore alla funzione da eseguire (es. sys_read())

System call handler

Identificativo della system call

```
__visible void do_syscall_64(unsigned long nr, struct pt_regs *regs)
{
        struct thread_info *ti;

        enter_from_user_mode();
        local_irq_enable();
        ti = current_thread_info();

        if (likely(nr < NR_syscalls)) {
                nr = array_index_nospec(nr, NR_syscalls);
                regs->ax = sys_call_table[nr](regs);
        }

        syscall_return_slowpath(regs);
}
```

Questo array contiene dei puntatori a funzione alle system call

Application Binary Interface

- La **Application Binary Interface (ABI)** è un insieme di convenzioni tra programmi utente e SO
- Es., in x86, il passaggio di parametri è via:
  - System Call number: EAX
  - Parametri di ingresso: EBX, ECX, EDX, ESI, EDI, EBP
  - Parametro di uscita: EAX
- Il kernel ne garantisce la stabilità ad ogni versione

https://linux-kernel-labs.github.io/refs/heads/master/lectures/syscalls.html

Implementazione di una system call

1. Inserire la syscall in un nuovo file all'interno dei sorgenti

   es.: `<sorgenti>/kernel/mysyscall.c`

2. Modificare il Makefile nella cartella del nuovo file

   es. (in `<sorgenti>/kernel/Makefile`): `obj-y += mysyscall.o`

3. Aggiungere una nuova riga alla system call table

   es. (per x86): `<sorgenti>/arch/x86/entry/syscalls/syscall_64.tbl`

4. Ricompilare il kernel

https://www.kernel.org/doc/html/latest/process/adding-syscalls.html

Esempio di system call (lato kernel)

```
SYSCALL_DEFINEn(mysyscall, int, PARAMETRO1, char *, PARAMETRO2, ....)
{

    // .... implementazione della system call ....

    return <VALORE LONG>;
}
```

Utilizzare la macro **SYSCALL_DEFINEn** (invece della sintassi classica del linguaggio C) per dichiarare la chiamata di sistema
Serve per esportare la definizione ad altri tool esterni

Esempio di system call (lato kernel)

```
SYSCALL_DEFINE3(mysyscall, pid_t, pid, char __user *, buffer, size_t, buf_size)
{

    // .... implementazione della system call ....

    return <VALORE LONG>;
}
```

Esempio:
System call per **cercare un processo con il PID indicato** come parametro
Ritorna una stringa con il nome del processo

Esempio di system call (lato kernel)

```
SYSCALL_DEFINE3(mysyscall, pid_t, pid, char __user *, buffer, size_t, buf_size)
{
    struct task_struct * mytask;
    char nome_processo[TASK_COMM_LEN];
    size_t dim;

    mytask = find_task_by_vpid(pid);                    // ricerca del PCB, in base al PID

    if(!mytask) {
        printk(KERN_DEBUG "Processo non trovato: %d\n", pid);        // ricerca fallita
        return -ESRCH;
    }

    __get_task_comm(nome_processo, TASK_COMM_LEN, mytask);        // legge il nome del processo
    printk(KERN_DEBUG "Processo trovato: %d = %s\n", pid, nome_processo);

    dim = (buf_size < TASK_COMM_LEN) ? buf_size : TASK_COMM_LEN;

    if( copy_to_user(buffer, nome_processo, dim) ) {

        printk(KERN_DEBUG "Errore di accesso alla memoria: %p\n", buffer);    // copy_to_user() fallita
        return -EFAULT;
    }

    return 0;
}
```

<sorgenti>/kernel/mysyscall.c

Esempio di system call (lato kernel)

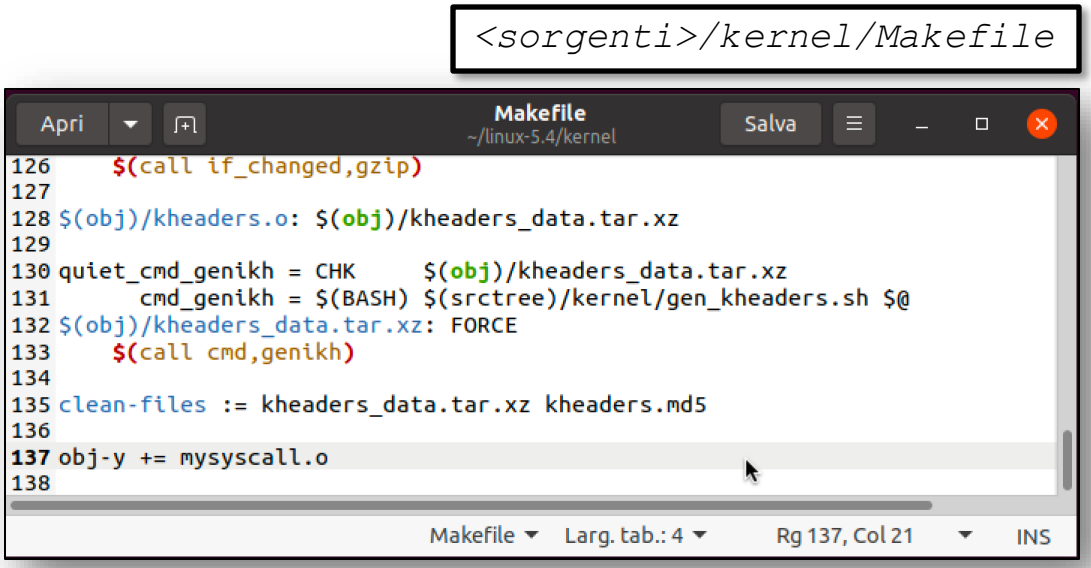

- Copiamo il file "mysyscall.c" nei sorgenti del kernel, nella sottocartella "kernel"
- Modifichiamo "kernel/Makefile"

System call table

System Call Table (Linux 5.4)
<sorgenti>/arch/x86/entry/syscalls/syscall_64.tbl

```
#
# 64-bit system call numbers and entry vectors
#
# The format is:
# <number> <abi> <name> <entry point>
#
# The __x64_sys_*() stubs are created on-the-fly for sys_*() system calls
#
# The abi is "common", "64" or "x32" for this file.
#
0       common  read                    __x64_sys_read
1       common  write                   __x64_sys_write
2       common  open                    __x64_sys_open
...

332     common  statx                   __x64_sys_statx
333     common  io_pgetevents           __x64_sys_io_pgetevents
334     common  rseq                    __x64_sys_rseq

# La nuova system call
335     common  mysyscall               __x64_sys_mysyscall

...
```

Accedere alla system call da user-space

- Per la **nuova system call**, non esiste alcuna funzione nelle librerie di sistema!
- Occorre scrivere una funzione "**wrapper**" apposita per la nuova system call

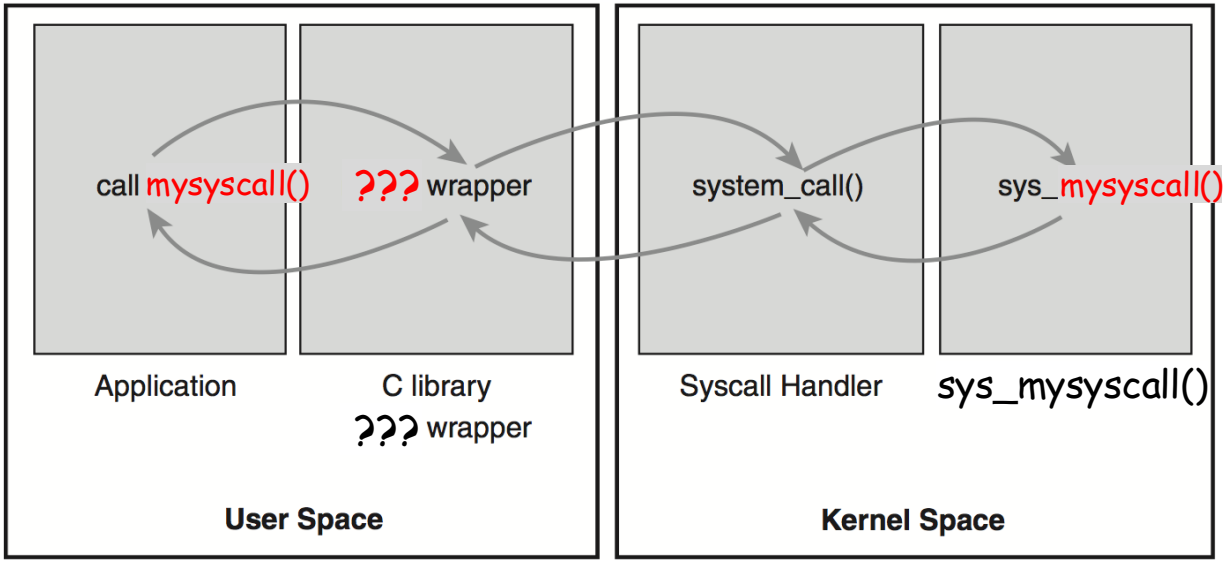

Accedere alla system call da user-space

- La libreria C fornisce un wrapper generico denominato "**syscall()**"

```
#define __NR_read 0

ssize_t my_read(int fd, void *buf, size_t count)
{
        return syscall(__NR_open, fd, buf, count);
}
```

Esempio di system call (lato user)

```
#include <stdio.h>
#include <sys/types.h>
#include <unistd.h>
#include <sys/syscall.h>

#define __NR_mysyscall 335      // NOTA: Utilizzare lo stesso valore usato in syscall_64.tbl

long mysyscall(pid_t pid, char * buffer, size_t buf_size) {

        return  syscall(__NR_mysyscall, pid, buffer, buf_size);
}

int main() {

        long err;
        char nomeprocesso[16];

        err = mysyscall( getpid(), nomeprocesso, 16 );

        if(err) {
                perror("mysyscall fallita");
                return -1;
        }

        printf("Risultato mysyscall: %s\n", nomeprocesso);

        return 0;
}
```

Avvertenze

- Le chiamate di sistema devono **verificare la validità dei parametri di ingresso** dal processo chiamante
  - Ad esempio, se si passa in ingresso un PID, occorre accertarsi che il PID esista veramente nel sistema!
  - Altrimenti, è a rischio la **sicurezza** del kernel
- In particolare, occorre garantire che i **puntatori di memoria** passati siano validi
  - Prevenire che la system call legga/scriva aree di memoria non autorizzate
  - Utilizzare **copy_from_user()** e **copy_to_user()** per garantire la copia sicura dei dati da/verso il processo

Un esempio di modulo kernel malevolo (rootkit)

Linux kernel rootkit

https://github.com/m0nad/Diamorphine

Diamorphine

Diamorphine is a LKM rootkit for Linux Kernels 2.6.x/3.x/4.x/5.x/6.x (x86/x86_64 and ARM64)

Features

- When loaded, the module starts invisible;
- Hide/unhide any process by sending a signal 31;
- Sending a signal 63(to any pid) makes the module become (in)visible;
- Sending a signal 64(to any pid) makes the given user become root;
- Files or directories starting with the MAGIC_PREFIX become invisible;
- Source: https://github.com/m0nad/Diamorphine

Linux kernel rootkit

- Nascondere processi
- Nascondere file e cartelle
- Nascondere connessioni
- Ottenere una shell di root
- Backdoor

- Attenzione! Può danneggiare il sistema, procedere con cautela

Linux kernel rootkit

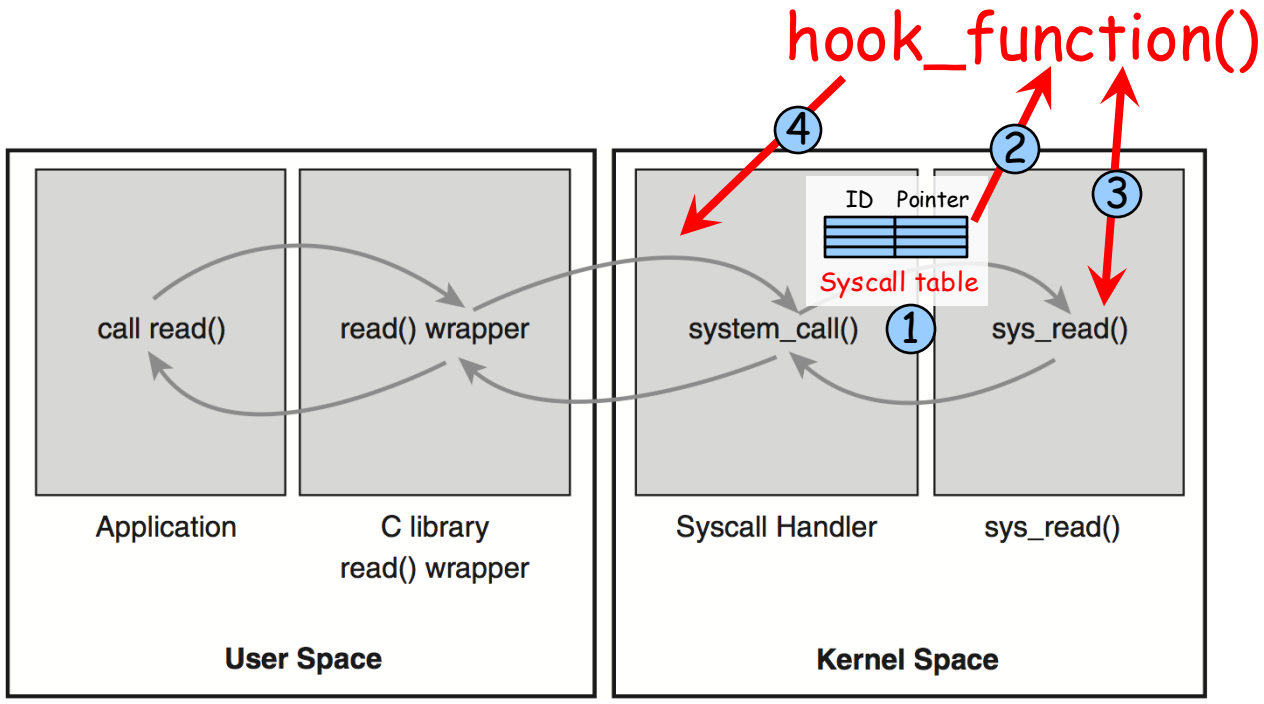

Tecnica dello hooking:

1. Nella syscall table, si inserisce un puntatore ad una funzione malevola
2. Quando un processo chiama la syscall vittima (es. read), il kernel segue la tabella e chiama la funzione malevola
3. La funzione malevola chiama la system call
4. La funzione malevola **modifica i risultati della system call vittima** (es. omette un file o un processo, per nasconderlo)

DRM rootkit

Sony, Rootkits and Digital Rights Management Gone Too Far

https://techcommunity.microsoft.com/t5/windows-blog-archive/sony-rootkits-and-digital-rights-management-gone-too-far/ba-p/723442